МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»

ОТЧЕТ

Лабораторная работа № 3

по дисциплине «Методы машинного обучения в автоматизированных системах обработки информации и управления»

ИСПОЛНИТЕЛЬ:	Хижняков В.М
	ФИО
группа ИУ5-22М	
	подпись
	"23" апреля 2024 г.
ПРЕПОДАВАТЕЛЬ:	<u> Гапанюк Ю.Е.</u>
	ФИО
	подпись
	" " 2024 г.

Москва – 2024

Задание лабораторной работы

- Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете. Просьба не использовать датасет, на котором данная задача решалась в лекции.
- Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
 - масштабирование признаков (не менее чем тремя способами);
 - обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
 - обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
 - отбор признаков:
 - один метод из группы методов фильтрации (filter methods);
 - один метод из группы методов обертывания (wrapper methods);
 - один метод из группы методов вложений (embedded methods).

Выполнение работы

Текстовое описание датасета

В качестве данных для анализа используется датасет AutoRu1.csv, представляющий собой таблицу, содержащую информацию о проданных автомобилях на сайте auto.ru за определенный период.

Для анализа в ЛР используются не все признаки.

Импорт библиотек

```
Ввод [1]: import pandas as pd import matplotlib.pyplot as plt import numpy as np import seaborn as sns from sklearn.model_selection import train_test_split from sklearn.preprocessing import StandardScaler from sklearn.preprocessing import MinMaxScaler from sklearn.preprocessing import RobustScaler from sklearn.preprocessing import MaxAbsScaler import scipy.stats as stats
```

Подключение Google Диска для работы с Google Colab

```
Ввод [2]: # from google.colab import drive # drive.mount('/content/drive')
```

Чтение данных

```
Ввод [3]: data = pd.read_csv('../data/zomato.csv')
Ввод [4]: data.head()
  Out[4]:
                                                       url
                                                                 address
                                                                            name online_order book_table
                                                                                                             rate votes
                                                                942, 21st
                                                              Main Road,
                      https://www.zomato.com/bangalore/jalsa-
              0
                                                               2nd Stage,
                                                                             Jalsa
                                                                                            Yes
                                                                                                        Yes 4.1/5
                                                                                                                    775
                                                 banasha...
                                                            Banashankari,
                                                             2nd Floor, 80
                     https://www.zomato.com/bangalore/spice-
                                                               Feet Road,
                                                                             Spice
                                                                                            Yes
                                                                                                        No 4.1/5
                                                                                                                    787
                                                  elephan...
                                                                 Near Big
                                                                          Elephant
                                                             Bazaar, 6th ...
                                                             1112, Next to
                 https://www.zomato.com/SanchurroBangalore?
                                                            KIMS Medical
                                                                            Churro
                                                                                            Yes
                                                                                                        No 3.8/5
                                                                                                                    918
                                                             College, 17th
                                                                              Cafe
                                                                  Cross...
                                                                1st Floor,
                                                                           Addhuri
                   https://www.zomato.com/bangalore/addhuri-
                                                             Annakuteera,
                                                                            Udupi
                                                                                            No
                                                                                                        No 3.7/5
                                                               3rd Stage,
                                                                           Bhojana
                                                            Banashankar...
                                                             10, 3rd Floor,
                     https://www.zomato.com/bangalore/grand-
                                                                 Lakshmi
                                                                            Grand
                                                                                            No
                                                                                                        No 3.8/5
                                                                                                                    166 8
                                                              Associates,
                                                                            Village
                                                   village...
                                                            Gandhi Baza...
Ввод [5]: data.shape
  Out[5]: (51717, 17)
Ввод [6]: len(data['listed_in(type)'].unique())
  Out[6]: 7
```

Первичная обработка данных

Оставим в исходной выборке лишь некоторые признаки:

```
Ввод [7]: data.drop(['url', 'address', 'name', 'votes', 'phone', 'reviews_list', 'dish_like
```

```
<class 'pandas.core.frame.DataFrame'>
           RangeIndex: 51717 entries, 0 to 51716
           Data columns (total 10 columns):
            #
                Column
                                              Non-Null Count Dtype
            0
                online_order
                                              51717 non-null
                                                              object
            1
                book_table
                                              51717 non-null
                                                              object
            2
                rate
                                              43942 non-null
                                                              object
            3
                location
                                              51696 non-null
                                                              object
            4
                rest_type
                                              51490 non-null
                                                              object
            5
                cuisines
                                              51672 non-null
                                                              object
                approx_cost(for two people)
                                              51371 non-null
                                                              object
            7
                menu_item
                                              51717 non-null
                                                              object
            8
                listed_in(type)
                                              51717 non-null object
            9
                listed_in(city)
                                              51717 non-null object
           dtypes: object(10)
           memory usage: 3.9+ MB
           Удалим пропуски:
 Ввод [9]: for column in data.columns:
             if (data[column].isnull().sum() != 0):
               print(column, ':', data[column].isnull().sum())
           rate : 7775
           location : 21
           rest_type : 227
           cuisines : 45
           approx_cost(for two people) : 346
Ввод [10]: data = data.dropna()
Ввод [11]: data.isnull().sum()
  Out[11]: online_order
                                           0
           book_table
                                           0
                                           0
           rate
                                           0
           location
                                           0
           rest_type
           cuisines
                                           0
           approx_cost(for two people)
                                           0
                                           0
           menu_item
                                           0
           listed_in(type)
                                           0
           listed_in(city)
           dtype: int64
Ввод [12]: data.shape
  Out[12]: (43533, 10)
```

Ввод [8]: data.info()

Обработка строкового представления числа

```
Ввод [13]: import re
           rate_p = '[\d]+([.,][\d]+)?'
           def parse_rate(s):
               if isinstance(s, str) and re.search(rate_p, s) is not None:
                   for catch in re.finditer(rate_p, s):
                       return int(float(catch[0].replace(',', '.')) * 10)
               else:
                   return None
           coast_p = '[\d] + ([.,][\d] +)?'
           def parse_coast(s):
               if isinstance(s, str) and re.search(coast_p, s) is not None:
                   for catch in re.finditer(coast_p, s):
                       return int(catch[0].replace(',', ''))
               else:
                   return None
           data['rate'] = data['rate'].apply(parse_rate)
           data['approx_cost(for two people)'] = data['approx_cost(for two people)'].apply(people)']
           # Если остались наны
           data = data.dropna()
           data['rate'] = data['rate'].astype('int64')
           data['approx_cost(for two people)'] = data['approx_cost(for two people)'].astype(
           data['menu_item'] = data['menu_item'].apply(lambda x: len(x)).astype('int64')
           Закодируем признаки:
           LabelEncoder
Ввод [14]: from sklearn.preprocessing import LabelEncoder
Ввод [15]: letype = LabelEncoder()
           learrtype = letype.fit_transform(data["listed_in(type)"])
           data["listed_in(type)"] = learrtype
           data = data.astype({"listed_in(type)":"int64"})
Ввод [16]: leeng = LabelEncoder()
           learren = leeng.fit_transform(data["rest_type"])
           data["rest_type"] = learren
           data = data.astype({"rest_type":"int64"})
Ввод [17]: lecuisines = LabelEncoder()
           learrm = lecuisines.fit_transform(data["cuisines"])
           data["cuisines"] = learrm
           data = data.astype({"cuisines":"int64"})
Ввод [18]: |lelocation = LabelEncoder()
           learrm = lelocation.fit_transform(data["location"])
           data["location"] = learrm
           data = data.astype({"location":"int64"})
```

```
Ввод [19]: lelc = LabelEncoder()
learrm = lelc.fit_transform(data["listed_in(city)"])
data["listed_in(city)"] = learrm
data = data.astype({"listed_in(city)":"int64"})
```

CountEncoder

```
Ввод [20]: # !pip install category_encoders

Ввод [21]: from category_encoders.count import CountEncoder as ce_CountEncoder

Ввод [22]: ce_CountEncoder1 = ce_CountEncoder()
data["online_order"] = ce_CountEncoder1.fit_transform(data['online_order'])
```

FrequencyEncoder

```
Ввод [23]: ce_CountEncoder3 = ce_CountEncoder(normalize=True)
data["book_table"] = ce_CountEncoder3.fit_transform(data['book_table'])
```

Ввод [24]: data.head()

Out[24]:

	online_ord	der	book_table	rate	location	rest_type	cuisines	approx_cost(for two people)	menu_item	listed_in(type)	list
(271	02	0.152776	41	1	24	1894	800	2	0	
	271	02	0.847224	41	1	24	816	800	2	0	
:	2 271	02	0.847224	38	1	19	653	800	2	0	
;	3 141	61	0.847224	37	1	73	2221	300	2	0	
	1 141	61	0.847224	38	4	24	1921	600	2	0	

Ввод [25]: data.info()

<class 'pandas.core.frame.DataFrame'>
Int64Index: 41263 entries, 0 to 51716
Data columns (total 10 columns):

#	Column	Non-Null Count	Dtype
0	online_order	41263 non-null	int64
1	book_table	41263 non-null	float64
2	rate	41263 non-null	int64
3	location	41263 non-null	int64
4	rest_type	41263 non-null	int64
5	cuisines	41263 non-null	int64
6	<pre>approx_cost(for two people)</pre>	41263 non-null	int64
7	menu_item	41263 non-null	int64
8	listed_in(type)	41263 non-null	int64
9	listed_in(city)	41263 non-null	int64
	67 (64/4) : (64/6)		

dtypes: float64(1), int64(9)

memory usage: 3.5 MB

Ввод [26]: data.dtypes

Out[26]: online_order int64 float64 book_table rate int64 location int64 rest_type int64 cuisines int64 approx_cost(for two people) int64 menu_item int64 listed_in(type)
listed_in(city) int64 int64 dtype: object

Разделение выборки

Ввод [27]: data.describe()

Out [27]:

	online_order	book_table	rate	location	rest_type	cuisines	approx_cost(for two people)
count	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000
mean	22660.793568	0.741129	37.020115	35.715096	45.289727	1208.839129	603.914063
std	6144.123431	0.249846	4.399848	26.406399	26.085202	670.720623	464.942973
min	14161.000000	0.152776	18.000000	0.000000	0.000000	0.000000	40.000000
25%	14161.000000	0.847224	34.000000	12.000000	24.000000	590.000000	300.000000
50%	27102.000000	0.847224	37.000000	31.000000	37.000000	1255.000000	500.000000
75%	27102.000000	0.847224	40.000000	54.000000	73.000000	1700.000000	750.000000
max	27102.000000	0.847224	49.000000	91.000000	86.000000	2366.000000	6000.000000

В качестве целевого признака возьмем признак rate.

```
Ввод [28]: # DataFrame не содержащий целевой признак
           Y = data['rate']
           X_ALL = data.drop('rate', axis=1)
```

Ввод [29]: X_ALL

Out[29]:

	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item	listed_in(type)	liste
0	27102	0.152776	1	24	1894	800	2	0	
1	27102	0.847224	1	24	816	800	2	0	
2	27102	0.847224	1	19	653	800	2	0	
3	14161	0.847224	1	73	2221	300	2	0	
4	14161	0.847224	4	24	1921	600	2	0	
51709	14161	0.847224	88	25	1785	800	2	6	
51711	14161	0.847224	88	25	101	800	2	6	
51712	14161	0.847224	88	6	866	1500	2	6	
51715	14161	0.152776	26	6	1207	2500	2	6	
51716	14161	0.847224	26	7	1231	1500	2	6	

```
Ввод [30]: Ү
  Out[30]: 0
                    41
                    41
           2
                    38
           3
                    37
                    38
                    37
           51709
                    25
           51711
           51712
                    36
           51715
                    43
           51716
                    34
           Name: rate, Length: 41263, dtype: int64
Ввод [31]: # Функция для восстановления датафрейма
           # на основе масштабированных данных
           def arr_to_df(arr_scaled):
               res = pd.DataFrame(arr_scaled, columns=X_ALL.columns)
               return res
Ввод [32]: # Разделим выборку на обучающую и тестовую
           X_train, X_test, y_train, y_test = train_test_split(X_ALL, data['rate'],
                                                                test_size=0.2,
                                                                random_state=1)
           # Преобразуем массивы в DataFrame
           X_train_df = arr_to_df(X_train)
           X_test_df = arr_to_df(X_test)
           X_train_df.shape, X_test_df.shape
  Out[32]: ((33010, 9), (8253, 9))
```

Масштабирование признаков

Масштабирование на основе Z-оценки

```
Ввод [33]: x_col_list = ['approx_cost(for two people)', 'cuisines', 'rest_type']
```

```
Ввод [34]: # Обучаем StandardScaler на всей выборке и масштабируем cs11 = StandardScaler() data_cs11_scaled_temp = cs11.fit_transform(X_ALL) # формируем DataFrame на основе массива data_cs11_scaled = arr_to_df(data_cs11_scaled_temp) data_cs11_scaled
```

Out[34]:

	online_order	ne_order book_table		rest_type	cuisines	approx_cost(for two people)	menu_item	listed_in(type)	li:
0	0.722847	-2.354894	-1.314663	-0.816171	1.021542	0.421747	-0.454082	-2.398267	
1	0.722847	0.424648	-1.314663	-0.816171	-0.585704	0.421747	-0.454082	-2.398267	
2	0.722847	0.424648	-1.314663	-1.007853	-0.828729	0.421747	-0.454082	-2.398267	
3	-1.383419	0.424648	-1.314663	1.062311	1.509083	-0.653667	-0.454082	-2.398267	
4	-1.383419	0.424648	-1.201053	-0.816171	1.061798	-0.008418	-0.454082	-2.398267	
41258	-1.383419	0.424648	1.980033	-0.777835	0.859028	0.421747	-0.454082	2.728160	
41259	-1.383419	0.424648	1.980033	-0.777835	-1.651735	0.421747	-0.454082	2.728160	
41260	-1.383419	0.424648	1.980033	-1.506226	-0.511157	1.927326	-0.454082	2.728160	
41261	-1.383419	-2.354894	-0.367911	-1.506226	-0.002742	4.078154	-0.454082	2.728160	
41262	-1.383419	0.424648	-0.367911	-1.467889	0.033041	1.927326	-0.454082	2.728160	

41263 rows × 9 columns

Ввод [35]: data_cs11_scaled.describe()

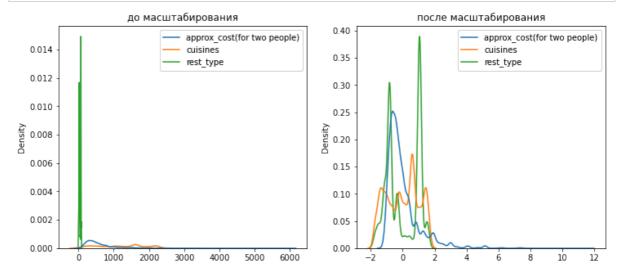
Out[35]:

	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_ite
count	4.126300e+04	4.126300e+04	4.126300e+04	4.126300e+04	4.126300e+04	4.126300e+04	4.126300e+
mean	-7.419485e-15	-1.037194e-14	3.465485e-14	1.616906e-15	-4.776935e-16	-2.669066e-15	1.197844e-
std	1.000012e+00	1.000012e+00	1.000012e+00	1.000012e+00	1.000012e+00	1.000012e+00	1.000012e+
min	-1.383419e+00	-2.354894e+00	-1.352533e+00	-1.736244e+00	-1.802321e+00	-1.212882e+00	-4.540819
25%	-1.383419e+00	4.246475e-01	-8.980923e-01	-8.161710e-01	-9.226593e-01	-6.536667e-01	-4.540819
50%	7.228468e-01	4.246475e-01	-1.785610e-01	-3.177981e-01	6.882363e-02	-2.235012e-01	-4.540819
75%	7.228468e-01	4.246475e-01	6.924506e-01	1.062311e+00	7.322972e-01	3.142056e-01	-1.767699
max	7.228468e-01	4.246475e-01	2.093643e+00	1.560684e+00	1.725271e+00	1.160605e+01	1.646400e+

Построим плотность распределения:

```
BBOД [36]: def draw_kde(col_list, df1, df2, label1, label2):
    fig, (ax1, ax2) = plt.subplots(
        ncols=2, figsize=(12, 5))
# первый график
    ax1.set_title(label1)
    sns.kdeplot(data=df1[col_list], ax=ax1)
# второй график
    ax2.set_title(label2)
    sns.kdeplot(data=df2[col_list], ax=ax2)
    plt.show()
```

Ввод [37]: draw_kde(x_col_list, data, data_cs11_scaled, 'до масштабирования', 'после масштаби



Обучаем StandardScaler на обучающей выборке и масштабируем обучающую и тестовую выборки:

```
Bвод [38]: cs12 = StandardScaler()
cs12.fit(X_train)
data_cs12_scaled_train_temp = cs12.transform(X_train)
data_cs12_scaled_test_temp = cs12.transform(X_test)
# формируем DataFrame на основе массива
data_cs12_scaled_train = arr_to_df(data_cs12_scaled_train_temp)
data_cs12_scaled_test = arr_to_df(data_cs12_scaled_test_temp)
```

Ввод [39]: data_cs12_scaled_train.describe()

Out[39]:

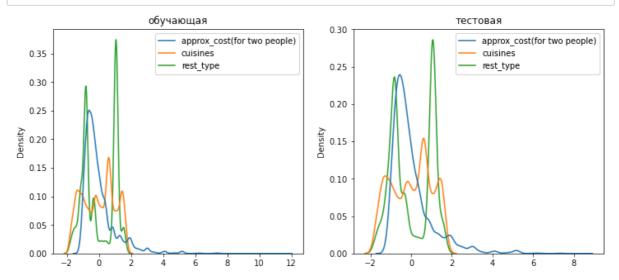
	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_ite
count	3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+
mean	-1.326590e-15	2.584993e-16	8.811828e-17	-4.397506e-17	-9.972668e-17	-1.018735e-15	1.491398e-
std	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+00	1.000015e+
min	-1.382830e+00	-2.368809e+00	-1.355221e+00	-1.732957e+00	-1.794476e+00	-1.212742e+00	-4.541267
25%	-1.382830e+00	4.221531e-01	-8.916524e-01	-8.126818e-01	-9.191788e-01	-6.515972e-01	-4.541267
50%	7.231547e-01	4.221531e-01	-1.821086e-01	-3.141996e-01	6.106488e-02	-2.199476e-01	-4.541267
75%	7.231547e-01	4.221531e-01	6.882650e-01	1.066213e+00	7.361454e-01	2.117020e-01	-1.802842
max	7.231547e-01	4.221531e-01	2.088431e+00	1.564695e+00	1.727554e+00	1.165042e+01	8.848344e+

```
Ввод [40]: data_cs12_scaled_test.describe()
```

Out[40]:

	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item	listed_i
count	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.
mean	0.002021	-0.021195	-0.018391	0.018340	0.025013	0.021623	-0.000744	-0.
std	0.999392	1.020263	0.996258	1.001023	0.991899	1.017010	0.998914	0.
min	-1.382830	-2.368809	-1.355221	-1.732957	-1.794476	-1.212742	-0.454127	-2.
25%	-1.382830	0.422153	-0.901113	-0.812682	-0.901316	-0.651597	-0.454127	-0.
50%	0.723155	0.422153	-0.182109	-0.314200	0.133262	-0.219948	-0.454127	-0.
75%	0.723155	0.422153	0.688265	1.066213	0.736145	0.319614	-0.138731	1.
max	0.723155	0.422153	2.088431	1.564695	1.727554	8.413044	16.460075	2.

Ввод [41]: draw_kde(x_col_list, data_cs12_scaled_train, data_cs12_scaled_test, 'обучающая',



Масштабирование Mean Normalization

```
Bвод [42]: class MeanNormalisation:

def fit(self, param_df):
    self.means = X_train.mean(axis=0)
    maxs = X_train.max(axis=0)
    mins = X_train.min(axis=0)
    self.ranges = maxs - mins

def transform(self, param_df):
    param_df_scaled = (param_df - self.means) / self.ranges
    return param_df_scaled

def fit_transform(self, param_df):
    self.fit(param_df)
    return self.transform(param_df)
```

Ввод [43]: sc21 = MeanNormalisation()
data_cs21_scaled = sc21.fit_transform(X_ALL)
data_cs21_scaled.describe()

Out[43]:

	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item
count	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000
mean	0.000192	-0.001519	-0.001068	0.001112	0.001420	0.000336	-0.000016
std	0.474780	0.359776	0.290180	0.303316	0.283483	0.078011	0.107475
min	-0.656619	-0.848743	-0.393542	-0.525512	-0.509501	-0.094280	-0.048818
25%	-0.656619	0.151257	-0.261674	-0.246443	-0.260135	-0.050656	-0.048818
50%	0.343381	0.151257	-0.052882	-0.095280	0.020931	-0.017099	-0.048818
75%	0.343381	0.151257	0.199865	0.323325	0.209012	0.024847	-0.019014
max	0.343381	0.151257	0.606458	0.474488	0.490499	0.905720	1.769431

Bвод [44]: cs22 = MeanNormalisation()
cs22.fit(X_train)

data_cs22_scaled_train = cs22.transform(X_train)
data_cs22_scaled_test = cs22.transform(X_test)

Ввод [45]: data_cs22_scaled_train.describe()

Out[45]:

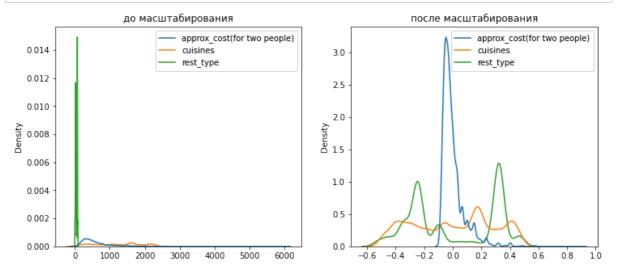
	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item
count	3.301000e+04 3.301000e+04		3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+04	3.301000e+04
mean	-4.283221e- 16	5 11//4/49=1/		2.766729e-18	-3.997169e-17	-1.368482e- 16	
std	4.748445e-01	3.583048e-01	2.903938e-01	3.032507e-01	2.839315e-01	7.774259e-02	1.075000e-01
min	-6.566192e- 01	-8.487428e- 01	-3.935418e- 01	-5.255124e- 01	-5.095006e- 01	-9.428024e-02	-4.881786e- 02
25%	-6.566192e- 01	1.512572e-01	-2.589264e- 01	-2.464426e- 01	-2.609799e- 01	-5.065608e-02	-4.881786e- 02
50%	3.433808e-01	1.512572e-01	-5.288241e- 02	-9.527980e- 02	1.733798e-02	-1.709903e-02	-4.881786e- 02
75%	3.433808e-01	1.512572e-01	1.998648e-01	3.233249e-01	2.090117e-01	1.645801e-02	-1.938025e- 02
max	3.433808e-01	1.512572e-01	6.064582e-01	4.744876e-01	4.904994e-01	9.057198e-01	9.511821e-01

Ввод [46]: data_cs22_scaled_test.describe()

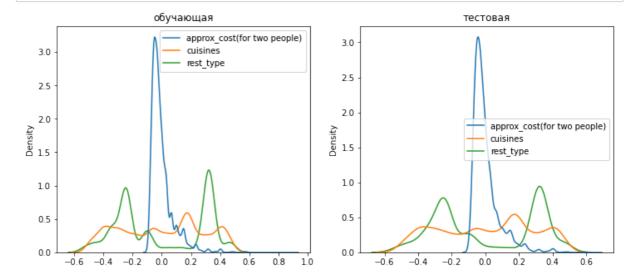
Out[46]:

	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item	listed_i
count	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.000000	8253.
mean	0.000960	-0.007594	-0.005341	0.005562	0.007102	0.001681	-0.000080	-0.
std	0.474548	0.365560	0.289303	0.303556	0.281627	0.079064	0.107382	0.
min	-0.656619	-0.848743	-0.393542	-0.525512	-0.509501	-0.094280	-0.048818	-0.
25%	-0.656619	0.151257	-0.261674	-0.246443	-0.255908	-0.050656	-0.048818	-0.
50%	0.343381	0.151257	-0.052882	-0.095280	0.037837	-0.017099	-0.048818	-0.
75%	0.343381	0.151257	0.199865	0.323325	0.209012	0.024847	-0.014913	0.
max	0.343381	0.151257	0.606458	0.474488	0.490499	0.654042	1.769431	0.

Ввод [47]: draw_kde(x_col_list, data, data_cs21_scaled, 'до масштабирования', 'после масштаби



Ввод [48]: draw_kde(x_col_list, data_cs22_scaled_train, data_cs22_scaled_test, 'обучающая',



MinMax масштабирование

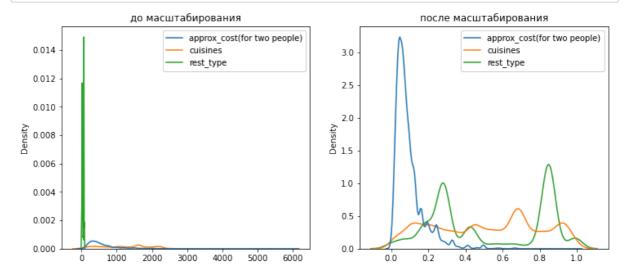
```
Ввод [49]: # Обучаем StandardScaler на всей выборке и масштабируем cs31 = MinMaxScaler() data_cs31_scaled_temp = cs31.fit_transform(X_ALL) # формируем DataFrame на основе массива data_cs31_scaled = arr_to_df(data_cs31_scaled_temp) data_cs31_scaled.describe()
```

Out [49]:

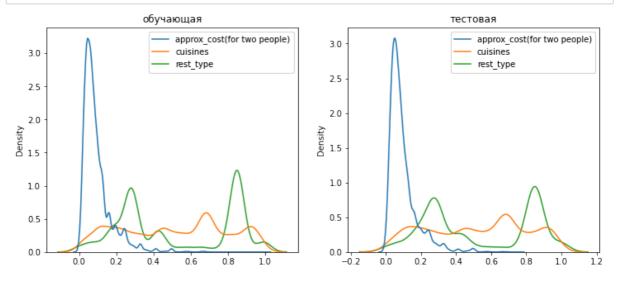
	online_order	book_table	location	rest_type	cuisines	approx_cost(for two people)	menu_item
count	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000	41263.000000
mean	0.656811	0.847224	0.392474	0.526625	0.510921	0.094616	0.026840
std	0.474780	0.359776	0.290180	0.303316	0.283483	0.078011	0.059109
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.000000	1.000000	0.131868	0.279070	0.249366	0.043624	0.000000
50%	1.000000	1.000000	0.340659	0.430233	0.530431	0.077181	0.000000
75%	1.000000	1.000000	0.593407	0.848837	0.718512	0.119128	0.016391
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000

```
Bвод [50]: cs32 = MinMaxScaler()
cs32.fit(X_train)
data_cs32_scaled_train_temp = cs32.transform(X_train)
data_cs32_scaled_test_temp = cs32.transform(X_test)
# формируем DataFrame на основе массива
data_cs32_scaled_train = arr_to_df(data_cs32_scaled_train_temp)
data_cs32_scaled_test = arr_to_df(data_cs32_scaled_test_temp)
```

Ввод [51]: draw_kde(x_col_list, data, data_cs31_scaled, 'до масштабирования', 'после масштаби



Ввод [52]: draw_kde(x_col_list, data_cs32_scaled_train, data_cs32_scaled_test, 'обучающая',



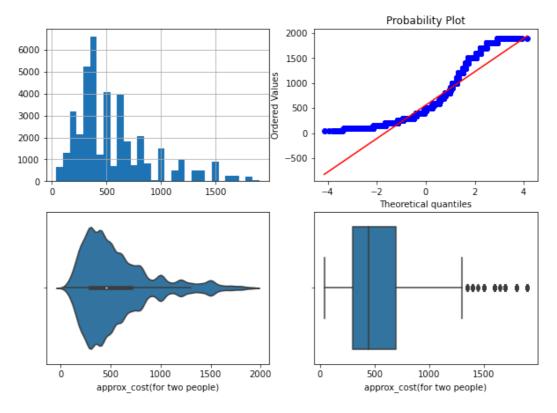
Обработка выбросов

```
Ввод [53]: def diagnostic_plots(df, variable, title):
               fig, ax = plt.subplots(figsize=(10,7))
               # гистограмма
               plt.subplot(2, 2, 1)
               df[variable].hist(bins=30)
               ## Q-Q plot
               plt.subplot(2, 2, 2)
               stats.probplot(df[variable], dist="norm", plot=plt)
               # ящик с усами
               plt.subplot(2, 2, 3)
               sns.violinplot(x=df[variable])
               # ящик с усами
               plt.subplot(2, 2, 4)
               sns.boxplot(x=df[variable])
               fig.suptitle(title)
               plt.show()
Ввод [54]: from enum import Enum
           class OutlierBoundaryType(Enum):
               SIGMA = 1
               QUANTILE = 2
               IRQ = 3
Ввод [55]: # Функция вычисления верхней и нижней границы выбросов
           def get_outlier_boundaries(df, col, outlier_boundary_type: OutlierBoundaryType):
               if outlier_boundary_type == OutlierBoundaryType.SIGMA:
                   K1 = 3
                   lower_boundary = df[col].mean() - (K1 * df[col].std())
                   upper_boundary = df[col].mean() + (K1 * df[col].std())
               elif outlier_boundary_type == OutlierBoundaryType.QUANTILE:
                   lower boundary = df[col].quantile(0.05)
                   upper_boundary = df[col].quantile(0.95)
               elif outlier_boundary_type == OutlierBoundaryType.IRQ:
                   IQR = df[col].quantile(0.75) - df[col].quantile(0.25)
                   lower_boundary = df[col].quantile(0.25) - (K2 * IQR)
                   upper_boundary = df[col].quantile(0.75) + (K2 * IQR)
               else:
                   raise NameError('Unknown Outlier Boundary Type')
               return lower_boundary, upper_boundary
```

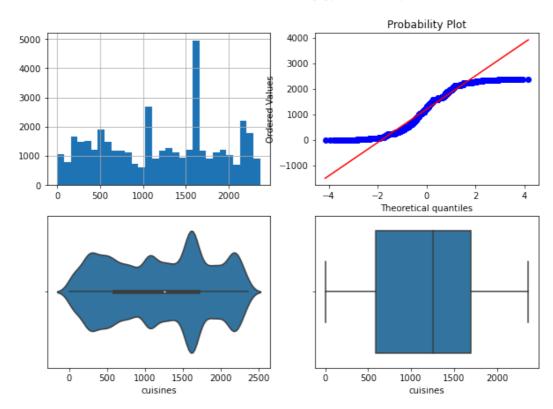
Удаление выбросов

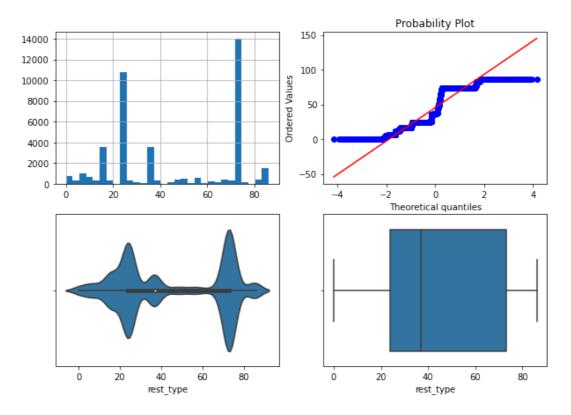
Воспользуемся методом OutlierBoundaryType.SIGMA:

Поле-approx_cost(for two people), метод-OutlierBoundaryType.SIGMA, строк-40290



Поле-cuisines, метод-OutlierBoundaryType.SIGMA, строк-41263

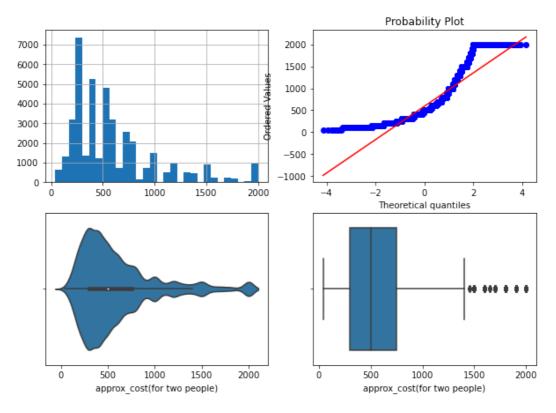




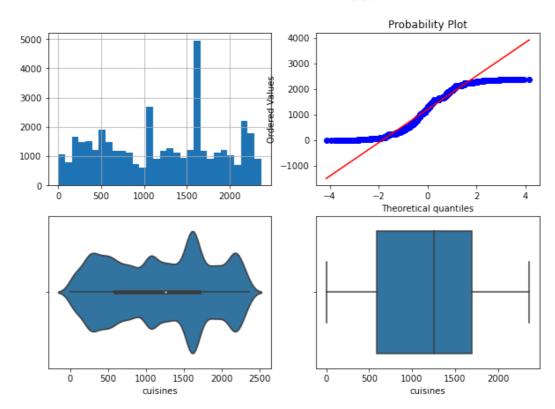
Замена выбросов

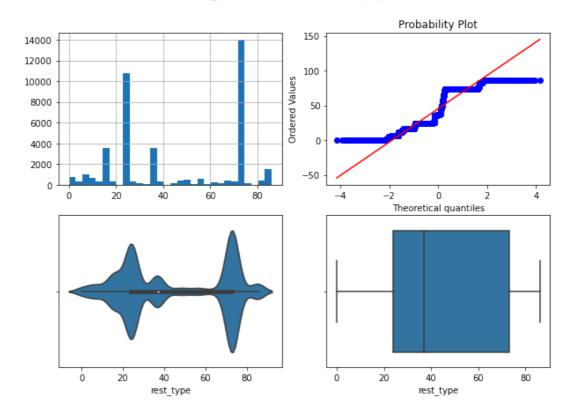
Проведём замену выбросов с помощью метода OutlierBoundaryType.SIGMA:

Поле-approx_cost(for two people), метод-OutlierBoundaryType.SIGMA



Поле-cuisines, метод-OutlierBoundaryType.SIGMA





Отбор признаков

Метод фильтрации (filter)

Воспользуемся методом "Удаление константных и псевдоконстантных (почти константных) признаков".

```
Ввод [58]: len(data['menu_item'].unique())

Out[58]: 4313

С помощью VarianceThreshold попробуем обнаружить больше таких признаков:

Ввод [59]: from sklearn.feature_selection import VarianceThreshold

Ввод [60]: selector = VarianceThreshold(threshold=0.15) selector.fit(data)

# Значения дисперсий для каждого признака selector.variances_

Out[60]: array([3.77493379e+07, 6.24213032e-02, 1.93581975e+01, 6.97281019e+02, 6.80421281e+02, 4.49855252e+05, 1.72655069e+05, 2.15402825e+06, 1.36985021e+00, 6.85144945e+01])
```

Удалим константные и псевдоконстантные признаки:

Метод обертывания (wrapper)

Будем использовать алгоритм полного перебора.

```
Ввод [62]: from mlxtend.feature_selection import ExhaustiveFeatureSelector as EFS from sklearn.neighbors import KNeighborsClassifier knn = KNeighborsClassifier(n_neighbors=3)
```

Best accuracy score: 0.65
Best subset (indices): (2, 3, 4, 5)
Best subset (corresponding names): ('location', 'rest_type', 'cuisines', 'approx _cost(for two people)')

Набор очень большой, применять данный метод к нему очень трудозатратно, ядро не справляется.

Метод вложений (embedded)

Применим линейную регрессию:

```
Ввод [65]: from sklearn.linear_model import Lasso
```

```
Ввод [66]: # Используем L1-регуляризацию
            e ls1 = Lasso(random state=1)
            e_ls1.fit(X_train, y_train)
            # Коэффициенты регрессии
            list(zip(data.columns.tolist(), e_ls1.coef_))
  Out[66]: [('online_order', 9.587560889424847e-05),
              ('book_table', -0.0),
('rate', 0.0035244206406411494),
             ('location', -0.013149794651649695),
('rest_type', -0.0002633022938218233),
('cuisines', 0.003541090138488024),
              ('approx_cost(for two people)', 2.1329815051364655e-05),
              ('menu_item', 0.0),
              ('listed_in(type)', -0.0)]
Ввод [67]: from sklearn.feature_selection import SelectFromModel
Ввод [68]: sel_e_ls1 = SelectFromModel(e_ls1)
            sel_e_ls1.fit(X_train, y_train)
            list(zip(data.columns.tolist(), sel_e_ls1.get_support()))
  Out[68]: [('online_order', True),
              ('book_table', False),
              ('rate', True),
              ('location', True),
              ('rest_type', True),
              ('cuisines', True),
              ('approx_cost(for two people)', True),
              ('menu_item', False),
              ('listed_in(type)', False)]
```